

# Smartphone-Based Recognition of Human Activities and Postural Transitions

Bruno M. Dobrovolski<sup>1</sup>, Eduardo A. Schmoller<sup>1</sup>

<sup>1</sup>Departamento Acadêmico de Informática – Universidade Tecnológica Federal do Paraná  
Pato Branco – PR – Brasil

{brunod,schmoller}@alunos.utfpr.edu.br

## 1. Introdução

Este trabalho apresentará resultados da aplicação de métodos de aprendizado de máquinas na predição de movimentos humanos. Foram implementados os seguintes métodos de aprendizado: KNN, Perceptron e SVM.

Os dados para base para treinamento e teste foram obtidos de [Dheeru and Karra Taniskidou 2017]. Essas informações são referente a sensores de um dispositivo móvel Galaxy Samsung S2. O *smartphone* foi mantido junto ao corpo dos voluntários em atividades de: Levantar, sentar, deitar, caminhar, subir escadas e descer escadas. Os testes foram executados com 30 voluntários e os dados coletados através dos sensores do smartphone, acelerômetro de 3 eixos e giroscópio de 3 eixos.

Os dados obtidos dos sensores foram pré-processados com a aplicação de filtros para remoção de ruídos, amostrados em intervalos constantes de tempo e normalizados. Também foram segmentados separando cada um dos 3 eixos e calculando várias informações estatísticas (totalmente descritas em citeDua:2017), como média, desvio padrão, máximo, mínimo, entre outras, totalizando 561 características. Cada conjunto de dados que representa os movimentos recebeu uma identificação. O conjunto de características e de identificações (*label*) são entradas para os algoritmos de classificação.

Como forma de validação do processo de aprendizado, o conjunto de dados de entrada foi dividido em dois subconjuntos denominados conjunto de treino e conjunto de testes. O conjunto de treino é utilizado no processo de treinamento, após o processo de treinamento o conjunto de testes é classificado e os resultados são comparados com os resultados esperados.

Ainda, os algoritmos foram alterados através da redução de dimensionalidade com o uso do método PCA. Como esse método não entrega um resultado ótimo, foi necessário variar o número de componentes para encontrar a melhor combinação.

Como métrica para a determinação da qualidade do processo de aprendizados foram utilizadas a acurácia da predição e utilização do *kappa score*. O *kappa score* funciona como uma validação do resultado apresentado pela acurácia, visto que ele considera em seu calculo os resultados falso-positivos e falso-negativos, colocando peso em cada uma das características.

## 2. Revisão

Esta seção apresenta os métodos aplicados para a classificação dos movimentos.

## 2.1. Perceptron

Separador linear através de uma função de *threshold*, reta esta que é definida através de pesos. O treinamento de um perceptron consiste na entrada de um conjunto de casos e calcular a saída para cada caso, após cada entrada os pesos são ajustados de forma a minimizar o erro na saída, o erro é definido como a diferença entre a saída e a saída esperada, não existe erro caso a saída e a saída esperada sejam iguais.

Perceptron de uma única camada apenas separam problemas lineares, para a classificação de classes que não sejam separáveis linearmente é necessário um perceptron de múltiplas camadas.

## 2.2. KNN

KNN algoritmo simples que realiza o aprendizado de todas as entradas e classifica as novas entradas com base na similaridade dos casos já aprendidos. Ao realizar a classificação de uma nova entrada é retornado  $k$  vizinhos mais próximos, classificação se dá pela maioria dos vizinhos.

## 2.3. SVM

SVM é um classificador definindo a separação entre as classes através de um hiperplano, a entrada são dados com *labels* e a saída é um hiperplano ótimo para categorização de novas entradas. Em duas dimensões o hiperplano é representado através de uma reta que divide o plano em duas partes.

## 2.4. PCA

Redutor de dimensionalidade selecionando as principais componentes, entre as formas de encontrar as componentes principais é buscar as projeções que maximizem a variância.

## 2.5. Testes Estatísticos

Testes estatísticos são utilizados para validação de hipóteses usando dados amostrais para decidir sobre a validade da hipótese.

Cenários típicos de uso de testes estatísticos em métodos de aprendizado: adição de etapas de processamento, comparar diversos algoritmos, validação de capacidade de generalização de um classificador. O princípio básico é a formulação de hipóteses e decidir se os dados mostram alguma evidencia para rejeição da hipótese.

### 2.5.1. Validação Cruzada

Validação cruzada é uma técnica que consiste em reservar uma parte do conjunto de dados para serem utilizados para testes após a etapa de treinamento.

Exemplos de métodos para validação cruzada: *HoldOut* (dividir em treino e teste), *K-fold* (k sub conjuntos de treino e teste), *Stratified K-Fold* (cada conjunto contem aproximadamente a mesma porcentagem de amostras de cada classe que o conjunto completo), *Leave-P-Out* (em um conjunto de  $n$  casos então  $n-p$  serão utilizados para treino e  $p$  casos para teste).


### 2.5.2. Matriz de Confusão

[http://www2.cs.uregina.ca/~hamilton/courses/831/notes/confusion\\_matrix/confusion\\_matrix.html](http://www2.cs.uregina.ca/~hamilton/courses/831/notes/confusion_matrix/confusion_matrix.html)

### 2.5.3. Kappa Score

<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC3900052/>  
<http://www.pmean.com/definitions/kappa.htm>  
<http://www.statisticshowto.com/cohens-kappa-statistic/>  
<https://academic.oup.com/ptj/article/85/3/257/2805022>

## 3. Resultados



**Figura 1. Acurácia e Kappa score KNN**

**Tabela 1. Resultados**

Método	Acurácia	Kappa Score
KNN	0.94	0.93
Perceptron	0.96	0.96
SVM	0.92	0.91
KNN + PCA		
Perceptron + PCA		
SVM + PCA		

## 4. Conclusões

...

## Referências

[Dheeru and Karra Taniskidou 2017] Dheeru, D. and Karra Taniskidou, E. (2017). {UCI} machine learning repository.